



# Metody estymacji błędu prognozy

## Bias-variance trade-off

# Uogólnianie modelu poza próbę uczącą

- Odnosi się do możliwości prognostycznych modelu w odrębnym i niezależnym od próby uczącej zbiorze danych
- Oszacowanie zdolności uogólniania jest podstawą do wyboru metod, modeli i jest miarą ich jakości
- Zagadnienie:  $Y, X, \hat{f}(X)$  bazujące na próbie uczącej  $T$

$$L(Y, \hat{f}(X)) = \begin{cases} (Y - \hat{f}(X))^2 \\ |Y - \hat{f}(X)| \end{cases}$$

$$L(G, \hat{G}(X)) = I(G \neq \hat{G}(X))$$

# Rodzaje błędu prognozy

- Błąd uczący (treningowy) – *training error*

$$\overline{err} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}(x_i))$$


- Błąd testowy (uogólniania) – *test (generalization) error*

$$Err_T = E[L(Y, \hat{f}(X))|T]$$

- Oczekiwany błąd testowy – *expected test error*

$$Err = E \left[ L(Y, \hat{f}(X)) \right] = E[Err_T]$$

# Bias-variance trade-off



- Istnieje pośredni poziom złożoności modelu dający najmniejszy możliwy  $Err_T$
- Problem: znaleźć  $\alpha$  (parametr złożoności) w  $f_\alpha(X)$

# Bias-variance decomposition

- $Y = f(X) + \varepsilon, \quad E(\varepsilon) = 0, \text{Var}(\varepsilon) = \sigma_\varepsilon^2$
- $$\begin{aligned} \text{Err}(x_0) &= E[(Y - \hat{f}(x_0))^2 | X = x_0] \\ &= \sigma_\varepsilon^2 + [E\hat{f}(x_0) - f(x_0)]^2 + E[\hat{f}(x_0) - E\hat{f}(x_0)]^2 \\ &= \sigma_\varepsilon^2 + \text{Bias}^2(\hat{f}(x_0)) + \text{Var}(\hat{f}(x_0)) \\ &= \text{Irreducible Error} + \text{Bias}^2 + \text{Variance} \end{aligned}$$
- Regresyjny model  $k$ -najbliższych sąsiadów:

$$\text{Err}(x_0) = \sigma_\varepsilon^2 + \left[ f(x_0) - \frac{1}{k} \sum_{i=1}^k f(x_{(i)}) \right]^2 + \frac{\sigma_\varepsilon^2}{k}$$

# Wybór modelu i ocena jego jakości

**Wybór modelu:** wybór najlepszego modelu spośród wielu oszacowań

**Ocena modelu:** po wybraniu najlepszego modelu należy oszacować spodziewany błąd związany z jego stosowaniem, tj. błąd testowy

Zbiór uczący

Zbiór walidacyjny

Zbiór testowy

Inne podejścia: krosvalidacja, bootstrap

# Kroswalidacja

1	2	3	4	5
Treningowy	Treningowy	Walidacyjny	Treningowy	Treningowy

- $k = 2, 3, \dots, K$ ;  $K$  to najczęściej 5 lub 10
- $\rho: \{1, \dots, N\} \rightarrow \{1, \dots, K\}$

$$CV(\hat{f}, \alpha) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}^{-\rho(i)}(x_i, \alpha))$$

- kroswalidacja jest silnie zależna od liczby obserwacji

# Bootstrap

- Ogólnie metoda statystycznej oceny precyzji z wykorzystaniem wielokrotnego losowania ze zwracaniem ze zbioru
- Z pierwotnego zbioru danych losujemy ze zwracaniem  $B$  prób o liczności takiej jak zbioru pierwotnego (np.  $B = 100$ )
- W każdej z  $B$  próbek estymujemy model i sprawdzamy jego jakość

$$\widehat{Err}_{boot} = \frac{1}{B} \frac{1}{N} \sum_{b=1}^B \sum_{i=1}^N L(y_i, \hat{f}^{*b}(x_i))$$

- Wersja uwzględniająca fakt, że część obserwacji powtarza się w próbkach i pierwotnym zbiorze danych

$$\widehat{Err}_{boot}^{(1)} = \frac{1}{N} \sum_{i=1}^N \frac{1}{|C^{-i}|} \sum_{b \in C^{-i}} L(y_i, \hat{f}^{*b}(x_i))$$

$C^{-i}$  to zbiór wskaźników próbek  $b$ , które nie zawierają obserwacji  $i$